

基于 YOLOv5 的番茄成熟度检测

摘要：实现番茄成熟度的准确检测对番茄产业智能化、系统化具有重要意义。本文提出了一种基于改进 YOLOv5 的番茄成熟度检测方法，前后三批共收集了番茄图片数据 4171 张，经人工标注后构建为最终的番茄数据集。该方法通过对 YOLOv5 模型添加不同的注意力机制，来提高模型对番茄特征的学习能力以及整体检测的准确性与可靠性。CBAM 注意力机制，引导网络更加专注于图像中有意义的部分；Biformer 注意力机制提高模型的处理效率和检测表现。本文还尝试将颈部网络中的 C3 模块替换成 YOLOv8 模型中的 C2f 模块，意图在保持轻量化的同时，通过 C2f 更有效的特征融合机制，进一步平衡模型的性能与效率。为了提高小目标的检测精度，添加了 NWD 损失函数。实验表明添加 NWD 损失函数和 CBAM 注意力机制以及 C2f 模块的改进 YOLOv5 模型在众多改进的模型中表现最好，对番茄成熟度的检测精度达到了 95 %，相比原模型提高了 0.014，并且其检测效果也优于原模型，相比原模型能正确检测出堆叠番茄的成熟度。

关键词：YOLOv5；成熟度检测；注意力机制；NWD 损失函数；C2f 模块

Tomato ripening detection based on YOLOv5

ABSTRACT: Achieving accurate detection of tomato ripeness is of great significance for intelligent and systematic tomato industry. In this paper, a tomato ripeness detection method based on improved YOLOv5 is proposed, and a total of 4171 tomato image data were collected in three

batches before and after, which were manually labeled and constructed into the final tomato dataset. The method improves the model's ability to learn tomato features as well as the overall accuracy and reliability of the detection by adding different attention mechanisms to the YOLOv5 model: the CBAM attention mechanism, which guides the network to focus more on the meaningful parts of the image; and the Biformer attention mechanism, which improves the processing efficiency and detection performance of the model. In this paper, we also try to replace the C3 module in the neck network with the C2f module in the YOLOv8 model, with the intention of further balancing the performance and efficiency of the model through the more effective feature fusion mechanism of C2f while maintaining lightweight. In order to improve the detection accuracy of small targets, the NWD loss function is added. Experiments show that the improved YOLOv5 model with the addition of the NWD loss function and the CBAM attention mechanism as well as the C2f module performs the best among the many improved models, with a detection accuracy of 95 % for tomato ripeness, which is improved by 0.014 compared to the original model, and its detection effect is also better than the original model, which can correctly detect the ripeness of stacked tomatoes compared to the original model.

KEY WORDS: YOLOv5; Ripeness testing; attention mechanism; NWD loss function; C2f module

1 绪论

1.1 研究背景及意义

番茄（学名：*Solanum lycopersicum*）是一种常见的蔬菜水果，原产于南美洲，现在已经广泛种植于全球各地。番茄属于茄科植物，是一年生草本植物，茎蔓生或直立，叶片羽状复叶，花小而黄色，果实为球形或椭圆形，成熟状态下通常为红色或黄色。番茄具有止血、降压、利尿、清热凉血、调和肝气、强健脾胃、促进消化、散热解毒、润燥解渴的功效。番茄果实味道酸甜可口，含有丰富的维生素 C、维生素 A、维生素 K、钾等营养物质，可增强血管功能,预防血管老化，还可以降低毛细血管的通透性、预防宫颈癌、膀胱癌和胰腺癌等疾病。番茄中的类黄酮,既有和防止其破裂的作用,还有预防血管硬化的特殊功效^[1]。番茄作为重要的经济作物可生食、烹饪、加工成各种美食，具有美容、健康、经济价值，其产量和销售额在全球农产品市场中占据重要地位。番茄及其加工产品在食品加工、饮料制造、调味品生产等领域都有广泛应用，为农民提供了丰厚的收入来源。在我国番茄产业分布比较广泛，华北地区、东北地区、华南地区、西南地区和华东地区等都有番茄产业分布包括种植和再加工。各地区根据气候条件、土壤状况和市场需求等因素，发展了不同规模和类型的番茄种植产业。我国是番茄种植和加工生产大国，种子市场规模超过 15 亿元，“十三五”期间以及后续时期，我国番茄产业继续稳步发展，番茄生产也逐渐形成了较为明显的优势区域，既确保了周年供应，又培育出一批适应市场需求的番茄新品种^[1]。番茄的成熟度直接影响其口感、营养价值和商业价值。因此，准确地检测番茄的成熟度对于生产者、加工商和消费者都具有重要意义。传统的番茄成熟度检测通常需要人工进行，耗时耗力且容易出现误差。随着科学技术尤其是计算机视觉技术的发展和深度学习的进一步应用，传统的人工检测已经成为制约番茄产业现代化、信息化、体系化的一大因素。基于人工智能的深度学习检测算法，逐渐成为当前目标检测领域的主流算法，尤其在智慧农业、智能医疗等部分交叉学科上发挥着越来越重要的作用。通过研究番茄成熟度检测技术，可以准确判断番茄的成熟程度，帮助农民更快速地了解番茄成熟度情况，从而提高生产效率，帮助农民确定最佳收获时间，避免过早或过晚采摘导致产量损失或品质下降。同时，精准的成熟度检测可以提高番茄的市场竞争力，满足消费者对优质番茄的需求，促进番茄产业的健康发展。

1.2 国内外研究现状

1.2.1 国内研究现状

目前，国内对番茄和其他果蔬的成熟度检测研究逐渐增多。研究者借助机器视觉、深度学习等技术，如 YOLOv4、YOLOv5、YOLOv7 等算法，开展成熟度检测研究，提高检测精度和效率。这些研究有助于优化农业生产管理，提升果蔬质量，推动数字农业发展。张玉程等将 YOLOv4 进行轻量化处理，构建跨纬度注意力机制模块，提高该模型的检测效

果,将 MobileNet 网络作为检测模型的特征提取模块,并采用深度可分离卷积操作代替常规卷积操作来降低参数容量从而提升运算的实时性;戎有丽等基于改进的 Faster RCNN 进行番茄成熟度分级和大小检测;吴俊峰等基于迁移学习和对三种卷积神经网络模型的超参数进行优化,建立了番茄成熟度检测的基本模型。YOLOv5 是一种快速、高效的目标检测算法,相较于 YOLOv3 和 YOLOv4,它具有更快的速度和更好的检测性能。国内多所高校以及农业研究院所对该模型进行不断改进和迭代更新。例如来自安徽工业大学的王勇、陶兆胜等人通过改进 YOLOv5s 多尺度目标检测层,加强同级成熟度的苹果纹理特征融合,弱化纹理特征分布差异带来的消极影响,提高模型泛化能力,模型的精确率、召回率、平均精度均值等均有部分提高^[3]。

1.2.2 国外研究现状

Huishan Lu^[4]等将番茄分为校正与预测两个模型,利用 PLS 回归的化学计量方法评价光谱波长与绿色灰度值之间的关系,建立了基于可见/近红外光谱和机器视觉的番茄成熟度无损检测模型;Aichen Wang^[5]等提出了一种前景-前景类别平衡方法和改进的 YOLOv8s 网络 NVW-YOLOv8s,用于同时检测和分割番茄果实;Muhammad Hammad Malik^[6]提出了一种新的基于改进 HSV(色调、饱和度、价值)颜色空间和改进分水岭分割的成熟番茄检测算法。

美国农业部的研究团队利用 YOLOv5 模型,开展了番茄成熟度检测的研究,探索了在不同生长环境下的适应性和效果。此外,一些欧洲国家的农业科学研究机构也在番茄成熟度检测方面进行了相关研究,尝试将 YOLOv5 等模型应用于农业生产中,提高番茄种植的效率和质量。

1.3 论文研究内容

本文的主要研究内容是采用改进后的 YOLOv5 模型对 4171 个番茄图片数据集进行训练,最终建立一个可以对番茄图片或者番茄视频进行准确度较高的成熟度检测的模型。具体工作如下:

(1)番茄数据集的采集及预处理。本次研究的数据集共 4171 张,分三批录入,主要是为了分别应对在模型验证过程中出现的各种复杂情景。第一批次总数为 2376 张,多为纯背景的单番茄图片;第二批次为 595 张,均为非常复杂自然环境下的多番茄图片;第三批则取两者之间,选择的是自然环境下,番茄特征明确或者拍摄角度良好的图片,经数据增强后共计 1200 张。由于受到自然环境尤其是光照因素和拍摄角度的影响,会造成图片的噪声、模糊,图片特征难提取等问题。因此要对初步采集的图片进行预处理。

(2)训练原 YOLOv5s 模型。分批训练番茄数据集,不断验证各批数据集的添加,对原模型的训练效果产生的影响,验证方法采用常规的控制变量,使用各个训练阶段后的模型来对一个具有各种背景的番茄采摘视频进行逐帧的检测比较。最终实现各个阶段的数据集添入都能提高模型检测能力的目的。

(3)基于改进后的 YOLOv5 的番茄成熟度检测模型的建立。对原 YOLOv5s 模型进行损失函数和网络结构的多次改动，并进行交叉验证，主要是基于 YOLOv5s 中的 P、R、mAP 等参数和执行 detect 文件后的检测框置信度来进行判断，并最终得出最佳的改进模型。

2 材料与方法

2.1 数据集采集

本文模型中的番茄数据集共分三批，均属于公开的图像数据集或者自制的标签数据集。所选西红柿品种大多为普通番茄，极少数为圣女果。这三批数据集几乎包含了大多数复杂情景。采集的图片涵盖了不同天气条件（如晴天、阴天）、不同时间段（如早上和傍晚）、不同果实叠加度（ $\leq 60\%$ ）、枝叶遮挡度（ $\leq 50\%$ ）、背景环境、成熟度等多种因素。这些图片既包括单一因素的影响，也包括多种因素混合的情况，为研究和分析提供了丰富的数据样本。

第一批番茄数据集共 2376 张，图片分辨率为 640×480 ，全为纯黑背景下的单个番茄图片。图 1 是对应批次的番茄图片数据集样本。




图 1 第一批数据集样本展示

第二批番茄数据集共 595 张分为两大类，图片分辨率分别为 640×640 和 3024×4032 ，前者是类似于第一批数据集，也是属于非自然背景下的番茄图片，不同于之前的是，还包括一些多番茄的图片；而后者是极为复杂的自然环境下的番茄图片。图 2 是对应批次的番茄图片数据集样本。



图 2 第二批番茄数据集样本展示

第三批番茄数据集共 1200 张，图片分辨率大小不一，是因为拍摄设备的不同以及同一设备像素设置的不同。该批次数据集虽然也是在较为复杂的自然背景下，但是又有着鲜明的特征（检测目标占整个图片尺寸的比例较大），复杂度较第二批次的数据集又远不如。图 3 是对应批次的番茄图片数据集样本。



图 3 第三批番茄数据集样本展示

2.2 番茄成熟度划分

番茄植物是一年生植物，生长期大约为 3-4 个月。其生长习性包括喜温暖湿润气候、需要充足阳光、适宜的土壤排水性和肥力、对水分需求较高等特点。番茄的生长周期包括幼苗期、生长期、开花期、结果期和成熟期。在不同阶段，番茄植株需要适当的养分、水分和温度，以确保果实的生长和成熟。番茄的幼苗期叶片呈淡绿色，植株嫩绿、叶片小；生长期叶片呈深绿色，叶片茂盛、植株高大；开花期植株绿色，有花蕾出现，花蕾呈黄绿色；结果期果实逐渐长大，开始呈现绿色；成熟期果实颜色饱满，呈现成熟状态，可能为红色或黄色。在本研究中为了能够实现成熟度检测的预期效果，只界定两个类别，并作如下的划分：在所有番茄的图像数据集中，认定纯红色和深红色的番茄为成熟期，其余颜色特征下的番茄均属于非成熟期。如图 4 和图 5 所示：



图 4 非成熟期番茄样本示例



图 5 成熟期番茄样本示例

2.3 图像预处理和样本标注

为了方便对图片进行管理和查找，将图片进行重命名，有助于保持数据集的整洁和有序。同时可以避免命名冲突和混乱，确保每张图片有唯一标识，也便于后续数据处理和模型训练，提高训练效率和准确性，每一批次都重新命名。实现脚本和效果见图 6。




图 6 图像预处理(重命名)

本文使用 LabelImg 软件对图像中的不同成熟度的番茄果实进行边界框标注，遮挡面积超过 40% 的番茄果实不被标注，以提高模型对复杂情况下番茄成熟度检测的能力。LabelImg 基于 Python 语言，借助可视化的界面实现目标样本标注。在 Anaconda3 中配置 labelImg 环境，安装与其他包类似，使用 pip 命令。在使用 labelImg 前，需按照目录结构 Vocdevkit\images 和 Vocdivkit\labels 来存放准备打标签数据集^[7]。

启动 Labelimg 后，先初始化 predefined_classes.txt 里面定义的类。在本文中，只分为两类分别是 ripe(成熟)和 unripe(非成熟)，将标注 LabelImg 在 Python 终端运行，然后点击 Open Dir，选择番茄图片数据集的文件夹存放位置为 Vocdevkit\labels，点击 Change Save Dir 用于选中保存类别标签的路径文件夹，在图片上找到符合要求的待检测物体(番茄)的位置用外接矩形框将其进行标注如图 7，目标番茄果实的标注信息以“.txt” 格式文件保存在 labels 文件夹。




图 7 labeling 标注图像面板

在图片标注时，注意以下类别索引和坐标值：YOLO 格式要求类别索引从 0 开始，标注框的坐标值是相对于图像宽度和高度的比例。而标签文件格式组成为：YOLO 标签文件每行表示一个目标，格式为"类别索引 中心点 x 中心点 y 宽度 高度"。在类别匹配时，要确保标注的类别与 YOLO 模型训练时使用的类别一致，避免混淆或错误。同时要确保标注框准确框选目标物体，避免遮挡或重叠(只标注符合覆盖率要求)，以提高模型训练的准确性。在标注时尽量不超出图像边界，否则可能导致训练时的错误或异常。时刻保存标注信息的格式和路径，以便后续训练和使用。

2.4 模型训练环境搭建

搭建基于 YOLOv5 的番茄成熟度检测模型训练环境，涉及从软件安装、数据准备到模型训练、评估的全过程。每一步都需要细心配置，以确保模型能够有效学习并准确识别不同成熟度的番茄。通过持续优化和调整，最终可以获得高性能的检测模型，为农业自动化和智能化提供有力支持。本文的主要实验环境为 Python 环境，版本为 3.8.0，YOLOv5 基于 pyTorch 框架，具体硬件信息见表 2.1。YOLOv5 源码来自于 GitHub，且大部分依赖库都是由 `pip install -r requirements.txt` 命令进行安装，少部分也是自己用 `pip` 命令和国内的镜像源进行安装。

表 1 环境硬件配置表

配置名称	详细信息
CPU	12th Gen Intel(R)Core(TM) i5-12500H
显卡	NVIDIA GeForce RTX 3050Ti Laptop GPU
显存	4GB
内存	DDR5 4800MHz SODIMM 8GB*2
虚拟环境	Anaconda
开发语言	Python3.8
操作系统	Windows11

深度学习框架	Pytorch1.13.0
--------	---------------

3 相关理论知识

3.1 卷积神经网络

卷积神经网络（Convolutional Neural Networks, CNN）^[8]是深度学习领域的一项重要技术，尤其在计算机视觉任务中表现出色。自 20 世纪 90 年代初提出以来，随着计算能力的提升和数据集的增长，CNN 已经成为图像分类、物体检测、语义分割等领域不可或缺的一部分。CNN 的设计灵感来源于生物视觉系统的结构与功能，特别是大脑皮层中的视觉处理机制。它利用局部感知、权值共享和池化操作等特性，有效提取图像中的空间特征，实现对图像的高层次理解。

CNN 从输入层开始，接收图像数据并做预处理。核心的卷积层利用滤波器提取特征，保留空间信息并减小模型复杂性。激活函数如 ReLU 引入非线性，池化层降维并保持重要特征，增强模型对特征位置变化的鲁棒性。全连接层整合特征，准备分类或回归输出。最后，输出层依据任务采用 Softmax^[9]转换为概率分布（分类）或线性输出（回归），完成图像识别或预测。

3.2 网络结构

3.2.1 Backbone(主干网络)

(1) CSP (Cross Stage Partial Networks)

CSP 是 YOLOv5s Backbone 的基石，由 Alexey Bochkovskiy^[10]提出，旨在解决神经网络中特征重用和计算冗余的问题。CSP 结构通过将网络分为两个分支，一个分支较早地输出特征，另一个分支进行更多的卷积运算后与早出分支的特征进行融合。这样，不仅减少了计算量，还促进了特征的多样化，提升了模型的性能。

(2) Darknet53

CSPDarknet53^[11]在 Darknet53 的基础上融入了 CSP 思想。Darknet53^[12]是一个高效的深度网络架构，由多个残差块组成，每个残差块包含两个或三个卷积层。这些残差块的堆叠形成了一个深层网络，能够有效提取不同层次的特征，同时通过残差连接解决了梯度消失问题，支持更深网络的训练。

(3) 特征金字塔结构

虽然 CSPDarknet53 本身并不直接构建特征金字塔，但在 YOLOv5s 中，通过 Neck 部分（通常包含 SPP 和 FPN 结构）与 Backbone 的结合，实现了多尺度特征的融合。这使得模型能够在不同分辨率的特征图上进行预测，从而有效检测不同大小的目标。

(4) Focus Layer

尽管 Focus 层位于输入层与 Backbone 之间，但它对于 Backbone 的输入特征有重要影响。通过减少空间维度（HxW）而增加通道数（C），Focus 层帮助网络更早地关注全局信息，这对于目标检测任务尤其有利。

(5) SPP^[13](Spatial Pyramid Pooling)

在某些 YOLOv5 变体中，SPP 模块可能集成在 Backbone 的末尾或 Neck 部分，用于提取多尺度的上下文信息。SPP 通过不同尺度的池化操作（如最大池化），将不同大小的感受野融合，增强了模型对对象尺度变化的鲁棒性

3.2.2 Neck(颈部网络)

YOLOv5s-5.0 的颈部网络（Neck）是整个模型架构中的关键部分，位于 Backbone（主干网络）和 Head（头部网络）之间，承担着特征融合与多尺度信息传递的重要职责。在这一阶段，网络通过复杂的结构设计来增强对不同尺度目标的检测能力，同时保证高效计算。

颈部网络的设计目标在于解决两个主要问题：一是如何有效整合来自 Backbone 的多层特征，二是如何在不同尺度上增强特征表达，以应对大小不一的目标检测挑战。通过特征融合和尺度增强，颈部网络为最终的检测头提供更加丰富且具有代表性的特征图。

YOLOv5s-5.0 的颈部网络采用了改进后的 CSP-PANet（Path Aggregation Network）结构。CSP-PANet 结合了 CSP（Cross Stage Partial Networks）和 PANet 的优点，前者通过分组处理和特征重用来提高计算效率，后者通过自顶向下和自底向上路径的特征聚合来增强多尺度特征融合。CSP 结构在颈部网络中的应用，主要是通过 CSP2_X 模块。这一模块将 Backbone 输出的特征图分割为两部分，分别通过两个不同的路径进行处理，然后重新合并。这样做减少了特征图的维度，同时保留了丰富的特征信息，降低了模型的计算复杂度。

YOLOv5s 颈部网络中另一个亮点是 SPPF 层，它是 SPP（Spatial Pyramid Pooling）的升级版。SPPF 通过在一个步骤中实现空间金字塔池化和特征融合，大大减少了计算量。该层在不同尺度上执行最大池化操作，然后将这些池化结果融合在一起，为模型提供多尺度的感受野，有助于提升对复杂目标结构的理解。

PANet 的加入进一步强化了特征的多尺度融合能力。它通过上采样和下采样的方式，将高层的语义信息与低层的细节信息相结合。这种自顶向下的路径（上采样）和自底向上的路径（下采样）的交互，形成了密集的特征连接，使得模型能够从不同层次特征中提取更全面的上下文信息。为了实现不同尺度特征图的有效融合，颈部网络中会使用上采样（如双线性插值）和下采样（如最大池化）操作。上采样使特征图尺寸增大，便于与更高分辨率的特征进行匹配，而下采样则减少特征图尺寸，提取更抽象的特征表示。这种操作有助于模型在不同尺度上捕捉目标，提高检测的鲁棒性。

3.2.3 Head(头部网络)

YOLOv5s 的头部网络是模型的输出层，负责生成预测结果，包括边界框坐标、物体类别以及物体存在的置信度。这一部分的设计直接关系到模型的检测精度和速度，是模型架构中至关重要的一环。

YOLOv5s 采用了多尺度检测策略，设置了多个检测头，通常称为 S、M、L（或相似命名）的输出层，对应不同尺度的特征图。每个检测头负责检测特定大小范围内的目标，这样设计可以提高模型对不同尺寸物体的检测能力。较小尺度的特征图（如 S 层）擅长检测小目标，因为它们保留了更多的空间信息；而较大尺度的特征图（如 L 层）则更擅长捕获大目标的全局特征。

在每个检测头内部，采用了锚框（Anchor Boxes）机制^[14]。锚框是一组预定义的框，每个框对应不同的宽高比和大小，覆盖了可能的目标尺寸和形状。模型在每个网格单元上预测一组锚框，包括每个框的中心坐标偏移、宽高缩放比例以及该框内是否有物体的置信度和物体的类别概率。这种设计简化了问题，从直接预测边界框坐标转变为预测相对于预设锚框的微调参数，提高了效率和准确性。

YOLOv5s 的头部网络训练时，使用的损失函数是基于 IOU（Intersection over Union）^[15]的改进版本，结合了分类损失、定位损失和置信度损失。这种复合损失函数确保模型不仅关注正确分类目标，也重视精确的边界框预测和合理的置信度分配。

3.3 工作原理

YOLOv5s-5.0 是一种高效的目标检测模型，工作流程始于对输入图像的预处理与 Resize 至固定尺寸，如 640x640 像素，并进行归一化。创新的 Focus 结构首先以切片操作增加特征维度而不过多降低空间分辨率，接着图像通过精简的 CSPDarknet Backbone 提取多尺度特征，结合 SPPF 模块融合不同尺度上下文信息。随后，特征在 Neck 部分经过上采样与下采样操作实现跨层特征融合，增强对目标尺度的适应性。在 Detection Head 阶段，模型预测每个网格的边界框、类别概率及置信度，最终借助非极大值抑制(NMS)筛选出最佳检测结果，提供实时、高精度的目标定位与分类。

4 基于改进的 YOLOv5s 的番茄成熟度检测算法

4.1 CBAM(Convolutional Block Attention Module)注意力模块

CBAM（Convolutional Block Attention Module）^[16]注意力机制是一种结合了通道注意力和空间注意力的模块，旨在提高卷积神经网络（CNN）对关键特征的聚焦能力，从而增强模型的性能。这种机制的设计灵感来源于人类视觉系统，即在复杂场景中快速锁定重要信息的能力，概述图如图 8。




图 8 CBAM 概述图

通道注意力 (Channel Attention) 关注的是输入特征图的通道维度，旨在识别哪些通道对于当前任务更为重要。通常分为三步：

(1)全局平均池化：首先，对输入特征图执行全局平均池化，将其压缩为一个 $1 \times 1 \times C$ 的向量，其中 C 为通道数。这一步骤提取每个通道的平均特征，反映了整个感受野的信息。

(2)特征压缩与激活：接下来，将得到的向量通过两个全连接层（中间通常伴随 **ReLU^[17]** 激活函数），第一个全连接层通常会减少通道数以减少计算量，第二个全连接层则恢复到原始通道数。这一过程可以视为对通道重要性的评估。

(3)Sigmoid 激活：最后，通过 Sigmoid 函数将特征映射到 $(0,1)$ 区间，得到每个通道的权重，表示每个通道的重要性程度。这些权重随后会被用于加权原特征图的通道，增强重要通道的贡献，抑制不重要的通道。




图 9 CAM 模块流程图

空间注意力机制 (Spatial Attention) 聚焦于特征图的空间维度，目的是识别图像中哪些区域对目标检测或分类最为关键。这一过程同样包含三个步骤：

(1)全局最大池化与平均池化：首先，分别对输入特征图进行全局最大池化和全局平均池化，生成两个 $1 \times 1 \times C$ 的向量。最大池化捕捉最显著的特征，而平均池化则提供背景上下文信息。

(2)特征重塑与卷积：将这两个向量拼接起来，并通过一个 1×1 卷积层，转换为二维的空间注意力图，尺寸与原始特征图相同。这一步骤使得每个位置都能根据其周围的上下文信息获得一个权重。

(3)Sigmoid 激活：最后，通过 Sigmoid 函数处理得到的二维图，生成范围在(0,1)之间的值，表示图像中每个位置的相对重要性。

将上述得到的通道注意力权重和空间注意力权重逐元素相乘，应用于原始特征图上，完成对每个通道每个位置上的特征强度的自适应调整。这样，既突出了关键通道中的重要区域，又抑制了非关键信息，实现了从通道到空间的精细注意力分配。

CBAM 相对于 YOLOv5s 的自带 C3 模块具有以下优势增强：

(1)特征表示：通过动态调整不同通道和空间位置的权重，CBAM 能有效增强网络对关键特征的学习，尤其是在面对复杂背景或目标遮挡的情况下。

(2)计算效率：尽管增加了注意力机制，但由于使用了轻量级的结构，如池化和小卷积核，CBAM 的计算成本相对较低，对模型的整体运行速度影响不大。

(3)泛化能力：通过引导网络关注关键信息，CBAM 有助于模型在未见过的数据上表现得更好，提高了模型的泛化能力。




图 10 SA 空间注意力机制原理图

4.2NWD(Normalized Weighted Diagonal)损失函数

NWD 损失函数^[18]的工作机制可以概述如下：

边界框表示：首先，它将边界框不是简单地当作坐标点来处理，而是将其建模为二维高斯分布。这样的表示方式能够捕捉框的位置及其不确定性，对于大小变化敏感的小目标尤为重要。

距离度量：接着，利用 Wasserstein 距离（也称为地球移动距离）来衡量两个概率分布之间的相似性。Wasserstein 距离考虑了从一个分布转移到另一个分布所需的最小“工作量”，在这个上下文中，可以理解为将一个边界框的分布调整为另一个的理想分布所需要的“成本”。它是分布之间差异的一种稳定且有意义的度量，尤其适合处理无重叠或轻微重叠的边界框情况。

归一化：为了使损失函数对尺度变化更加稳健，提出了归一化处理。归一化 Wasserstein 距离确保了度量的尺度不变性，即使目标尺寸变化，也能提供一致的优化信号，有助于模型更好地学习小目标的特征。

提升小目标检测：通过上述方法，NWD 损失函数能够在训练过程中给予小目标更多的关注，优化过程中不仅考虑位置的准确性，还考虑到目标尺度的精确匹配，从而显著提高了对小目标检测的精度和稳定性。

与 IOU 相比 NWD 在检测微小物体方面具有以下优势：（1）尺度不变性，（2）位置偏差的平滑性，（3）能够测量非重叠或相互包含的边界框之间的相似性。

在本文中，NWD 的加入，使得模型对小目标检测能力得到了很大提升，尤其是与 CBAM、C2f 模块的共同改进后的新模型，在交叉验证实验中取得了良好的效果。

4.3 Biformer (Bi-level Routing Attention Transformer)

4.3.1 双层路由注意力机制

(1)位置路由 (Position Routing)：在 Biformer^[19]中，每个图像块 (token) 都与一个位置路由器 (Position Router) 相关联。这个设计的目的是为了实现对图像块的关注度分配的优化。位置路由器通过分析图像块的内容和上下文，动态地决定哪些图像块是当前处理块的重要邻居。这意味着，与当前块关系密切的图像块会得到更高的注意力权重，而无关紧要的块则被相对忽略。这种机制减少了计算负担，因为不是所有的图像块都需要参与自注意力计算，而是仅关注那些被认为重要的部分。

(2)查询自适应 (Query Adaptation)：Biformer 不仅仅依赖于位置路由器来筛选注意力目标，它还通过查询自适应机制让每个查询 (query) 只与一小部分相关令牌 (tokens) 进行交互。这种机制允许模型更集中地处理关键信息，进一步减小了计算规模，提高了计算效率。查询自适应通过学习调整查询向量，使其更有效地与相关的关键信息匹配，从而减少对无关信息的注意力分散。

4.3.2 模块优势

减少内存占用：通过上述机制，Biformer 能够在不牺牲模型性能的前提下，显著减少参与自注意力计算的令牌数量，从而降低内存需求。

降低计算成本：由于只关注一小部分相关令牌，Biformer 的自注意力计算变得更加高效，尤其是在处理高分辨率图像或大数据集时，这种优化显得尤为关键。

4.4 C2f

YOLOv8 中的 C2f^[20]模块是对 YOLO 系列模型中网络结构的一个改进，它基于 YOLOv5 中的 C3 (Cross Stage Partial Network) 模块进行了优化设计。C2f 模块的主要目标是在不显著增加模型复杂度的前提下，增强模型的特征提取能力，提高检测精度和效率。

4.5 改进后的 YOLOv5 模型

对原模型进行了多次改进，包括将颈部网络的 C3 模块替换成 YOLOv8 中的 C2f 模块，在头部网络中增加一层 CBAM 模块或者 Biformer 模块，并且添加了 NWD 损失函数，增

强网络对较小目标以及较多目标的特征学习能力，虽然在一定程度上增加了计算成本，但是确有效提高了检测精度。

5 实验与结果分析

5.1 性能评价指标

混淆矩阵（Confusion Matrix）是一种在机器学习和统计分类中广泛使用的工具，用于评估和理解分类模型的性能。它以表格的形式展示模型预测类别与实际类别之间的比较结果，混淆矩阵的每一行代表实际类别，每一列代表预测类别。

混淆矩阵		真实值	
		Positive	Negative
预测值	Positive	TP	FP (Type II)
	Negative	FN (Type I)	TN

图 11 混淆矩阵

本研究采用 Precision 精确率（查准率、P）、Recall 召回率（查全率，R）、mAP 均值平均精度（mean Average Precision）来判定模型的检测能力。

Precision 为模型检测出来的正确正样本数占全部被识别出来的正样本数的比例；Recall 为召回率是指模型预测为正类的样本中，真正是正类的样本所占的比例；mAP 均值平均精度为各个类别平均精度的平均值。mAP@.5 是当 iou 为 0.5 时的 mAP；mAP@.5:.95 是当 iou 为 range(0.5:0.95:0.05)时的 mAP 的平均数。

5.2 消融实验对比

5.2.1 YOLOv5s 原模型

YOLOv5 原模型训练该番茄数据集，50 轮次后的指标如下表所示，之所以是 50 轮次，是因为在之前的实验中，50 轮次左右已经出现收敛的情况，但是由于后续将加入 NWD 损失函数，使得模型的收敛速度降低，在 60 轮次左右才会收敛。为了节省时间以及计算成本所以设定为 50 轮次，但也说明本实验所展现的性能指标并不一定是最终的指标。根据以往的模型训练过程判断，两种情况下 mAP 均值平均精度相差不会超过 0.03。由于所有的模型对比实验都是设定的 50 轮次，再加之与最终精度的浮动差不大，因此并不会影响各个改进模型之间的性能对比。从该表可以看出原始模型的精度不算低，再结合后续的改进模型，甚至部分更优，但是其对番茄视频的检测效果却远远不如改进模型，主要集中在多番茄图

片帧的检测时刻，具体检测结果对比见下一小节，表 1 为原 YOLOv5 模型对该数据集的训练结果，并使用 P、R、mAP 等指标以表格的形式表现出来。

表 1 YOLOv5s 原模型训练结果

Class	Images	labels	P	R	mAP@.5	mAP@.5:.95
all	873	1046	0.936	0.969	0.987	0.798
ripe	873	392	0.959	0.969	0.989	0.781
unripe	873	654	0.912	0.969	0.985	0.815

5.2.2 加入 NWD 损失函数后的 YOLOv5 模型

YOLOv5s 基于 IoU 的度量方法，对于小目标的位置的变化非常的敏感，对不同尺度物体的灵敏度差异很大，本文使用 NWD 替换标准 IoU，对小目标的检测有着比较明显的提升效果，其模型的性能结果如表 2。

表 2

Class	Images	labels	P	R	mAP@.5	mAP@.5:.95
all	873	1046	0.953	0.968	0.986	0.816
ripe	873	392	0.95	0.977	0.988	0.8
unripe	873	654	0.955	0.959	0.985	0.833

改进步骤如下：先在 loss.py 中的 class Computeloss 添加在 github 中找到的 wasserstein_loss 函数，该函数计算了两个边界框分布之间的 Wasserstein 距离的损失，用于优化目标检测任务中的预测边界框(pred)与实际目标边界框(target)的匹配。这里是基于概率分布理解边界框，并非直接使用原始的 Wasserstein 距离公式，而是进行了简化和适应性调整，特别适用于矩形框的比较。然后将 class Computeloss:中的 def_call_函数中原来的 iou loss 的代码注释调用，并用融合 IoU 和 NWD 两种度量的代码进行替换，源代码如图 12。定义了 iou_ratio 为 0.5，意味着 NWD 损失和 IoU 损失同等重要，虽然本文数据集中有相当部分的小数据集，但是由于数据集基数较大，再加之验证时间的不足，所以并没有调低 iou_ratio 的值。因此理论上，损失函数 NWD 在本数据集上的表现不一定为其最优效果。

5.2.3 加入 NWD+Biformer 注意力机制后的 YOLOv5 模型

Biformer 一般用于提高 Transformer 在处理视觉数据时面临的计算复杂度和内存消耗问题，提升特征图的质量，让网络不仅能捕获局部特征，还能更好地理解全局上下文信息，本文将 Biformer 模块加在骨干网络后，通过增强高层特征的表达力和效率，来提升模型的整体检测性能，改进后的网络结构图如图 13。




图 12 加入 Biformer 机制后 YOLOv5 模型的网络结构

通过对比实验可得，相对于原模型, P 和 $mAP@.5:.95$ 等指标有了较大提高，但是 R 确降低了 0.0；相对于只添加 NWD 损失函数的模型，P 和 $mAP@.5$ 指标有所上升，而 R 和 $mAP@.5:.95$ 较之下降，尤其是 $mAP@.5:.95$ 下降了 0.16，具体结果如表 3。Biformer 模块提高了模型在定位单个目标上的准确性，特别是对于高 IoU 阈值 ($IoU=0.5$) 的情况。但是使得模型对检测小目标或重叠目标的能力有所削弱，导致召回率降低，个人分析加入 Biformer 模块后模型可能过于集中于图像的某些局部特征，忽略了全局上下文或微笑细节，违背了引入模块的初衷。实验过程表明，加入 NWD+Biformer 模块的 YOLOv5 模型训练 50 轮次的时间为 4.749hours，而只加入 NWD 损失函数的模型训练 50 轮次的时间为 4.744hours。因此可以得出添加 Biformer 模块到 YOLOv5 模型并没有实现预期时间效率上的提升，根据训练完后产生的 exp 文件，可以得出在训练的空间成本上差别也不大。

为了进一步验证是否是 Biformer 与 YOLOv5 原有架构以及本数据集存在不兼容性，后续依然保留该改进，并与其他改进网络结构的调整方法进行对比试验。

表 3

Class	Images	labels	P	R	$mAP@.5$	$mAP@.5:.95$
all	873	1046	0.954	0.961	0.987	0.804
ripe	873	392	0.955	0.954	0.986	0.783
unripe	873	654	0.953	0.968	0.988	0.825

5.2.4 加入 NWD+CBAM 注意力机制后的 YOLOv5 模型

添加 CBAM 注意力机制的目的是增强网络对输入特征图中的关键信息的关注，同时抑制不重要的信息，这对本数据集在理论上是很适用的，因为在第二、三批添加的番茄图片中，复杂的自然背景下的番茄图片约占 40%，尤其是包括非成熟番茄的图片，其被检测的番茄与周围环境的颜色差异非常小。加入 CBAM 注意力机制，以此提升模型的代表能力和最终的性能，同时 CBAM 作为轻量级模块，几乎不会增加改进后模型的计算成本。

主要的改变在于网络的 head 部分，在“P5/32-large”特征层之后，即在编号为 23 的层之后新增了一层 CBAM 模块，是因为该层级的特征图尺寸较小（较高的感受野），但包含了高层语义信息，非常适合用于精确检测和分类。这样的插入点能够最大化 CBAM 对提升检测精度的贡献，尤其是在区分不同类别和精确定位方面，具体网络结构如图 14。




图 13 加入 CBAM 注意力机制后的 YOLOv5 模型的网络结构

根据表 4 对比表 1 可得，加入 NWD+CBAM 模块的模型相对于原模型，P 和 $mAP@.5:.95$ 等指标有提升，但是 R 和 $mAP@.5$ 略微降低。与加入 NWD+Biformer 模块的模型进行比较，变化情况和上述的对比较为相似，相对于只加入 NWD 损失函数的模型，R 和 $mAP@.5:.95$ 等指标又相对下降，P 准确率倒是增长了 0.007。

表 4

Class	Images	labels	P	R	$mAP@.5$	$mAP@.5:.95$
all	873	1046	0.96	0.954	0.986	0.807
ripe	873	392	0.955	0.946	0.986	0.788
unripe	873	654	0.965	0.962	0.987	0.827

5.2.5 加入 NWD+C2f 模块后的 YOLOv5 模型

本组改进的内容是将 head 部分的 C3 模块用 C2f 模块替换，如图 15。C2f 模块相较于 C3 模块，采用了梯度分流的思想。它将上一个输出层的通道分成两部分，一部分直接传递，另一部分经过卷积处理后再合并回去。C2f 通过引入更多的分支跨层连接，能够捕获到更多样化的特征信息，其与 CBAM 模块的结合使得模型对特征的捕获能力有了很大提升，这在后续的对比较实验中会体现出来。




图 14 加入 C2f 模块后的 YOLOv5 模型的网络结构

根据表 5 和上述的各表可得出，加入 NWD+C2f 模块的模型在各个指标上的表现相对于加入 NWD+CBAM、加入 NWD+Biformer、加入 NWD 等改进模型，并没有什么完全的提升，只有相对于原 YOLOv5 模型时，P 和 mAP@.5:.95 分别提升了 0.006 和 0.005。

表 5

Class	Images	labels	P	R	mAP@.5	mAP@.5:.95
all	873	1046	0.942	0.961	0.987	0.803
ripe	873	392	0.954	0.959	0.987	0.791
unripe	873	654	0.93	0.963	0.987	0.815

5.2.6 各阶段改进模型的综合实验对比

为了更全面且简要的分析不同的损失函数和网络结构的改变对模型泛化性能的影响，找到最佳的改进组合，使模型在未见过的数据集上也能保持良好的检测效果。采用上述的四个评价指标，通过九组实验（包括上面的五组）来进行对比，综合实验结果如下表 6：

表 6

NWD	CBAM	Biformer	C2f	P	R	mAP@.5	mAP@.5:.95
—	—	—	—	0.936	0.969	0.987	0.798
✓	—	—	—	0.953	0.968	0.986	0.816
✓	✓	—	—	0.96	0.954	0.986	0.807
✓	—	✓	—	0.954	0.961	0.987	0.804
✓	—	—	✓	0.942	0.961	0.987	0.803
✓	✓	✓	—	0.94	0.956	0.985	0.799
✓	✓	—	✓	0.95	0.974	0.987	0.806

√	—	√	√	0.93	0.969	0.984	0.803
√	√	√	√	0.928	0.959	0.983	0.797

根据上表的结果，可以得出在这八种改进方法中，只加入 NWD 损失函数的改进模型在 $mAP@.5:.95$ 指标上的提升非常显著，远高于其他改进模型；加入 NWD 损失函数和 CBAM 注意力机制以及 C2f 模块的改进模型（网络结构如图 16），虽然在 $mAP@.5:.95$ 指标上的提升不如前者，但是其整体的四个指标相对于原模型是全面增强。根据表 6 和图 17 该模型是所有改进模型中，指标提升整体性最优的一个，这在下一节的检测效果对比中将会充分体现。




图 15 NWD+CBAM+C2f 模块的 YOLOv5 模型网络结构




图 16NWD+CBAM+C2f 模块的 YOLOv5 模型训练结果图

虽然性能指标的幅度变化较大，并且在某些组合下的指标低于初始模型，但是在检测效果上确实得到了较大提升，尤其是针对小目标和多目标的情况，检测效果远远好于初始

模型。在第一次加入 NWD 损失函数和 CBAM 注意力机制时，对单个目标的检测性能指标达到较高的水平，但是在对番茄视频检测时，无法有效识别聚集在一起的番茄，或者将其标识为一个，并且对部分非成熟番茄和番茄叶片的分辨度不高，甚至将某些叶片识别为未成熟的番茄。因此不仅添加了两批复杂数据集，并且对原模型的网络结构和损失函数进行了略微改动，使其能够适应复杂的检测环境。

5.3 检测结果对比

为了方便，各改进模型均以简称表示。图 17 为 YOLOv5 原模型、加入 NWD 的改进模型的检测效果图、NWD+Biformer 改进模型等模型的检测效果图。



图 17




图 18

图 18 分别为 NWD+Biformer+CBAM+C2f 改进模型、NWD+C2f 改进模型、NWD+C2f+Biformer 改进模型等改进模型的检测效果图。

图 19 分别为 NWD+C2f+CBAM 改进模型、NWD+CBAM+Biformer 改进模型和 NWD+CBAM 改进模型的检测效果图。



图 19

综合分析各个改进模型对同一视频中某一帧图片的检测效果，可以看出相对原模型，大部分改进模型的检测置信度均有提升，但是各个改进都存在或多或少的问题。从图 19 可以看出 NWD+CBAM+Biformer+C2f 的改进模型由于模型的复杂度较高而存在对特征的过度学习的现象即过拟合。由图 22 得出加入 CBAM 改进的模型和加入 CBAM+Biformer 的改进模型出现了对同一目标的多个重叠检测框，通常是后处理阶段的非极大值抑制（NMS）可能没有充分地发挥作用，但是在本文中并未进一步探讨。通过上述所有检测效果图的对比，发现只有 NWD 损失函数+CBAM 注意力机制+C2f 模块的改进模型（图 21）检测标注出了所有的番茄（包括被覆盖的番茄），同时其表现出的置信度相对于原模型整体有了较大提升。

6 总结与展望

本文主要实现的是对原 YOLOv5s 模型进行一定程度上的改进，使得该模型能够实现番茄成熟度的实时检测，为了简化工作量和复杂度，番茄的类别只固定为两个，分别为成熟（ripe）和非成熟（unripe）。本文共收录了 4171 张图片数据集，既包括简单的番茄图片，又包括复杂的番茄图片。本文对原 YOLOv5 模型的网络结构进行了简单的改进，将 YOLOv8 中的 C2f 模块替换掉原 YOLOv5 模型的 C3 模块，又分别对颈部网络和头部网络添加新的 Biformer 模块和 CBAM 模块，同时又添加了 NWD 损失函数，增强了模型对复杂情况下番茄成熟度的检测能力。综合消融实验对比和检测结果对比得出，加入 NWD 损失函数+CBAM 注意力机制+C2f 模块的改进模型是所有改进模型中检测效果最优的，相对于原模型，其精确度提高了 0.014，对多目标和小目标的检测置信度也得到了较大提升。

尽管已经进行了网络结构的优化，未来工作可以进一步探索更高效的轻量化设计，可以尝试引入更为先进的模型压缩技术和知识蒸馏策略，使得算法在保持高检测精度的同时，减少计算量和内存占用，更适合于资源有限的嵌入式设备和实时应用。为了提高模型的泛化能力，可以研究更多样化的数据增强策略，除了 YOLOv5 自带的数据增强策略外并考虑

引入自适应学习率调整机制，让模型在训练过程中能更有效地利用训练数据，特别是在面对复杂光照、背景变化等实际应用场景时。

本文注重理论算法方面的实验，并没有结合 PySide6 等界面开发工具，优化用户体验，开发易于操作的前端系统，以便农业工作者直接使用，实现快速、直观的成熟度检测反馈。同时也没有采用 Python 语言下的 PYQT 库来创建用户界面，这些均是本文尚未完成的任务和展望，这些展望旨在推动番茄成熟度检测技术的持续进步，使之更加高效、精确，且能够更好地服务于现代农业的智能化需求。

参考文献

- [1] 张玉静,张铨锋,栗国栋,等.铁锌硒配施对番茄生长、果实抗氧化能力和糖代谢的影响[J/OL].中国土壤与肥料:1-12[2024-05-15].<http://kns.cnki.net/kcms/detail/11.5498.S.20240423.1428.002.html>.
- [2] 李君明,项朝阳,王孝宣,等. “十三五”我国番茄产业现状及展望[J].中国蔬菜,2021(02):13-20.DOI:10.19928/j.cnki.1000-6346.2021.2009.
- [3] 陶兆胜,石鑫宇,王勇,等.基于改进 YOLOv5s 的番茄叶片病害检测方法[J].沈阳农业大学学报,2023,54(06):712-721.
- [4] Huishan Lu et al. Rapid Assessment of Tomato Ripeness Using Visible/Near-Infrared Spectroscopy and Machine Vision[J]. Food Analytical Methods, 2017, 10(6) : 1721-1726.
- [5] Wang, A., Qian, W., Li, A., Xu, Y., Hu, J., Xie, Y., & Zhang, L. (2024). NVW-YOLOv8s: An improved YOLOv8s network for real-time detection and segmentation of tomato fruits at different ripeness stages. Computers and Electronics in Agriculture.
- [6] Malik H M ,Zhang T ,Li H , et al.Mature Tomato Fruit Detection Algorithm Based on improved HSV and Watershed Algorithm[J].IFAC PapersOnLine,2018,51(17):431-436.
- [7] 孙宇朝,李守豪,夏秀波,等.利用改进 YOLOv5s 模型检测番茄果实成熟度及外观品质[J].园艺学报,2024,51(02):396-410.DOI:10.16420/j.issn.0513-353x.2023-0859.
- [8] Leon, O. Chua. CNN: A Vision of Complexity[J]. International Journal of Bifurcation & Chaos, 1997.
- [9] Mikolov T , Kombrink S , Burget L ,et al.Extensions of recurrent neural network language model[C]//International Conference on Acoustics, Speech, and Signal Processing.IEEE, 2011.
- [10] Bochkovskiy, A., Wang, C., & Liao, H.M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection. ArXiv, abs/2004.10934.
- [11] Wang, C., Liao, H.M., Yeh, I., Wu, Y., Chen, P., & Hsieh, J. (2019). CSPNet: A New Backbone that can Enhance Learning Capability of CNN. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 1571-1580.
- [12] Redmon J , Farhadi A .YOLOv3: An Incremental Improvement[J].arXiv e-prints, 2018.DOI:10.48550/arXiv.1804.02767.
- [13] K. He, X. Zhang, S. Ren and J. Sun, "Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 37, no. 9, pp. 1904-1916, 1 Sept. 2015.
- [14] S. Ren, K. He, R. Girshick and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 6, pp. 1137-1149, 1 June 2017.
- [15] Yu, J., Jiang, Y., Wang, Z., Cao, Z., & Huang, T.S. (2016). UnitBox: An Advanced Object Detection Network. Proceedings of the 24th ACM international conference on Multimedia.
- [16] Woo, S., Park, J., Lee, J., & Kweon, I. (2018). CBAM: Convolutional Block Attention Module. ArXiv, abs/1807.06521.
- [17] Glorot X , Bordes A , Bengio Y .Deep Sparse Rectifier Neural Networks[J].Journal of Machine Learning Research, 2011, 15:315-323.
- [18] Wang J , Xu C , Yang W ,et al.A Normalized Gaussian Wasserstein Distance for Tiny Object Detection[J]. 2021.

- [19] L. Zhu, X. Wang, Z. Ke, W. Zhang and R. Lau, "BiFormer: Vision Transformer with Bi-Level Routing Attention," 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023, pp. 10323-10333Biformer **Biformer**
- [20] Sun, Yujia et al. "Context-aware Cross-level Fusion Network for Camouflaged Object Detection." International Joint Conference on Artificial Intelligence (2021).